Research Plan v5：信息流里的观点茧房——怎样形成、能否察觉、如何逃离

2026-11-06 · 取代 v4 的研究问题与总体设计；v4 的定义和命题大部分保留，改为服务于用户侧的问题。可行性核查的原始数字见 v5 可行性记录，脚本在 analysis/v5_feasibility。

0. 一句话问题

在婚恋、家庭这类日常议题上，短视频信息流可能**保留了话题，却让用户看到的观点越来越偏**。用户自己看不见这种偏，能用的按钮又可能连整个话题一起删掉。我们问：用真实数据训练的推荐器，会不会把一个用户推进这样的"观点茧房"？用户能不能察觉？逃出来要付出什么代价？

1. 从第一性原理出发

1.1 茧房是一种关系，不是一种内容

"茧房"说的不是某条视频好不好，而是**一个人看到的内容分布，与某个参照分布相比，偏了多少**。所以定义它需要三样东西：

1. 一个议题，以及议题内要比较的属性（例如"是否把个案归结为某一性别的普遍特征"）；
2. 这个人的曝光分布：推荐器接下来会给他看什么；
3. 一个参照：平台上本来有什么（供给），平台平均给大家看什么，或者关掉个性化后会看到什么。

没有参照就谈不上"偏"。这一点后面决定了用户为什么察觉不到（1.3），也决定了偏斜可以分解成几部分（4.2）。

1.2 话题集中不等于茧房

一个人刷到很多育儿视频，本身很正常，这是兴趣。值得担心的是：**同一个议题里，他看到的说法和叙事越来越单一**，而他会把这当成"大家都这么想"。所以我们把用户状态画在两个维度上：

- 议题占比 m：信息流里有多少是这个议题（兴趣的强弱）；
- 观点偏斜 V：议题内部，目标属性的占比比参照高多少（对数几率）。

m 高、$V \approx 0$ 是兴趣；m 高、V 大才是观点茧房；$m \approx 0$ 时议题不在信息流里，V 没有意义。已有的推荐系统研究大多只测 m 或类别多样性（见第 5 节），而这个概念最早被提出时担心的正是观点：Sunstein（2006）的"信息茧房"、Pariser（2011）的"过滤气泡"。

1.3 用户为什么看不见自己的茧房

用户只看得到自己的信息流，看不到参照。即使他想判断，也只能从自己刷到的有限条视频里估计 V，而目标叙事在议题内往往只占少数。估计需要多少条视频，可以直接算出来（命题 4）。我们的初步计算是：对议题内的少数叙事，要可靠察觉一个 2 到 4 倍的偏斜，需要看到数百到数千条同议题视频，按真实用户的议题曝光率换算，远超一个人短期内会刷到的量。

这带来两个推论：一是"察觉"需要外部参照，而《互联网信息服务算法推荐管理规定》要求平台提供的"关闭个性化推荐"选项，恰好能提供这个参照；二是平台自己最容易算出 V（它掌握曝光概率），用户侧只能靠抽样。

1.4 茧房怎样形成，又怎样被拆掉

推荐器把视频表示成向量或语义 ID，用户的历史决定他在这个空间里的位置。用户对某条视频的反馈（看完、点赞、“不感兴趣”），会让与它**相似**的视频一起变多或变少。于是有一个关键事实：

> 形成和逃离走的是同一条路。用户偏好 A 类视频时，A 的占比能被个性化放大多少，与用户对 A 点”不感兴趣”时 A 能被单独压低多少，取决于同一个量：推荐器的表示在议题内部把 A 与其他视频分开的程度。

如果表示主要按话题组织，A 和同议题的其他视频挨得很近，那么：个性化很难单独放大 A（观点偏斜主要来自供给和全局排序，而不是个性化）；用户的反馈也很难单独压低 A，压低 A 必然连带压低整个议题。命题 2、3 把这件事写成可检验的公式。

可行性试点给出了一个更尖锐的可能：OneRec 的表示足以在议题内区分以偏概全叙事，个性化能把它放大；而它从日志学到的”不感兴趣”却朝相反方向起作用，对这类视频点得越多，看到的越多（第 7 节）。“进得去、出不来”是需要正式检验的核心可能性。

表示里”分开 A 与其他视频”的信息可能来自两处：内容本身（标题、描述的语义），或者用户行为（喜欢 A 的人也喜欢 A’，于是两者在行为表示里靠近）。快手 OneRec 的语义 ID 由视频文本描述的 embedding 量化得到，技术报告没有提到加入行为信号；按物品 ID 学习的推荐模型则能直接利用共同互动。比较这两类推荐器，可以检验”观点信息主要存在于用户网络里”这一猜测。

1.5 范围

- 研究对象是**曝光与控制**。不测量信念、态度或伤害，不判定哪种观点正确，不把”正反均衡”当作目标。已有大型实验显示，减少同温层内容的曝光不一定改变态度（Nyhan 等, Nature 2023），所以我们不做这方面的推断。
- 用户的调整目标（“保留议题，减少某种叙事”）作为明确的实验情境给出，不从匿名日志中推断真实用户的意愿。
- 全部实验离线进行：用公开的推荐模型和日志做模拟，不在真实平台上操纵账号。

2. 为什么重要

- **人会从信息流推断社会规范。**在 Bluesky 上的随机实验中，按互动排序的信息流让用户感知到的党派敌意上升、对群体规范的判断变差（Brady 等, Nature 2026）；按互动排序比按用户自述偏好排序更多放大愤怒和对外群体的敌意（Milli 等, PNAS Nexus 2025）。
- **用户的即时行为和长期意愿可能不一致。**平台只观察互动，用户在当下会点开、看完的内容，未必是他希望多看的（Kleinberg 等, Management Science 2024）。这正是”想逃出茧房”的情境：用户的行为在喂养茧房，他的意愿却想离开。
- **监管点名了信息茧房，但现有功能停在话题层面。**2024 年 11 月”清朗·网络平台算法典型问题治理”专项行动把”同质化推送营造信息茧房”列为重点，要求关闭算法推荐的选项便捷有效、可删除用户标签。2025 年 5 月，快手上线”信息茧房自我评估”和”一键破茧”，评估的是推荐页的**内容类型、内容偏好和推荐强度**，调整的是内容类型、兴趣标签和推送强度；小红书、抖音也上线了内容偏好评估。按命题 0，这类基于类型和标签的评估与调整，对议题内部的观点偏斜是看不见、也改不动的，除非标签本身对应观点。
- **日常议题上的叙事有现实分量。**网信办的专项行动曾点名”恶意挑动性别对立”。但”性别对立”作为治理标签本身有争议（Guan & Shang, Media and Communication 2026），所以我们不用这个标签，而用可操作的定义：是否把某一性别群体整体描绘为负面，或把个案归结为该性别的普遍特征。

3. 研究问题与假设

主问题：在中文短视频的日常议题上，用真实行为数据训练的推荐器，会不会让一个用户在保留议题的同时陷入观点茧房？用户能否察觉？用户可用的各种操作能以多大代价把他带出来？

On everyday issues in Chinese short-video feeds, do recommenders trained on real interaction data push individual users into viewpoint cocoons while keeping the topic, can users detect them, and at what cost can user-side actions get them out?

三个子问题对应用户的经历：进去、察觉、出来。它们研究的是同一个量 V 的产生、观测和改变，并由同一个机制（表示中的属性对比，命题 2）解释，所以是一个问题的三个侧面，而不是三个独立的题目。

	研究问题	主要产出
RQ1 形成	当用户的互动偏向议题内某一种叙事时，推荐器会让他看到的观点构成偏多少、多快？与议题占比的增长相比如何？这种偏斜有多少来自供给与全局排序，多少来自个性化？由推荐器的什么性质决定？	用户状态 (m_t, V_t) 的轨迹；偏斜的三段分解；各推荐器的属性对比与话题对比；真实日志中的用户间离散度
RQ2 察觉	只看自己的信息流，用户（或用户侧工具）需要看多少条同议题视频，才能可靠察觉给定大小的偏斜？参照从哪里来？平台现有的"茧房评估"能否发现观点茧房？	察觉所需样本量与时间（结合真实曝光率）；话题层面评估对 V 的敏感度
RQ3 逃离	对已陷入观点茧房的用户，各种操作——"不感兴趣"、多看想保留的内容、主动搜索、删除历史、关键词屏蔽、关闭话题标签、关闭个性化、重置、外部过滤工具——能把 V 降多少？代价（努力、议题内想保留内容的损失、议题外信息流的变化）是多少？停下后效果能维持多久？任何用户策略最多能做到什么程度？	每种策略在 $(\Delta V, \Delta \log m)$ 平面上的位置与曲线；努力–效果前沿；持续时间；最优规划的上界

假设（事先登记，结果两种方向都有意义）：

- **H1a（排序放大，双向）**：按互动排序的平台平均曝光中，目标叙事的占比是否高于供给中的占比。初步证据不一致：明显标签词视频的点赞率高于同议题其他视频（8.0% 对 5.2%），但 LLM 判出的同类视频点赞率与其他视频相近，且在已曝光视频中获得的曝光反而偏少（第 7 节）。
- **H1b（对偶）**：个性化造成的观点偏斜，增长速度与推荐器表示中的属性对比成正比；用户的反馈能多精准地消除偏斜，取决于同一个属性对比。不同属性的对比大小不预设方向：试点中立场型的以偏概全（+1.1）大于内容型的冲突叙事（+0.65），与"立场更难区分"的直觉相反（第 7 节）。
- **H1c（用户网络，双向）**：按物品 ID 学习的推荐器，属性对比是否高于基于内容的推荐器，取决于受众是否按叙事分化。
- **H1d（真实日志）**：真实用户之间，议题内目标叙事的曝光占比比随机分配更分散。初步证据：离散系数约为随机基准 95% 分位的 4 倍（第 7 节）。
- **H2a**：对议题内的少数叙事，靠自己刷到的视频察觉中等偏斜，所需曝光量远超真实用户的议题曝光量；平台侧用曝光概率可以直接算出。
- **H2b**：只基于内容类型或标签分布的茧房评估，对 V 不敏感。
- **H3a**：关闭话题标签只在标签与属性相关时改变 V，否则 $\Delta V = 0$；关闭整个议题则 $m \to 0$，等于放弃议题（命题 0）。
- **H3b**：过滤类操作的效果由其查全率与误伤率决定（命题 1），LLM 过滤优于关键词屏蔽。
- **H3c**：在把"不感兴趣"实现为负向更新的推荐器中，对 A 点"不感兴趣"每降一单位 V 要付出 t/c 单位的议题损失（命题 2）；多看想保留的内容能降低 V 而不损失议题，在代价上优于"不感兴趣"。
- **H3f**：在只从日志学习的生成式推荐器中，"不感兴趣"对目标内容的作用是正的，用户点得越多看到得越多。OneRec 上的初步结果已出现这一现象（第 7 节），正式实验在更多用户、OneRec-8B 和议题内属

性上确认。

- **H3d**：反复点"不感兴趣"，议题占比先于观点偏斜坍塌（命题 3）。
- **H3e**：改变推荐器状态的操作（反馈、删除历史）停下后会逐渐失效，失效速度取决于推荐器记住多长的历史和用户原本的偏好；只改输出的操作（过滤）停下即失效。
- **H4**：以上结论在另一个议题、另一种属性和另一种推荐器上仍成立。

4. 定义与理论

4.1 定义

记号：全部视频 $\mathcal{I}$；议题 k；时刻 t 用户 u 的曝光分布 $\pi_{u,t}$（下一条推荐是 i 的概率），$\pi(G)=\sum_{i\in G}\pi(i)$。

1. **议题语料** $I_k=\{i\in\mathcal{I}:\mathrm{rel}_k(i)=1\}$，由标注规范判定。
2. **目标属性** $s:I_k\to\{+,-,0,?\}$。**目标集** $A=\{s=+\}$，**保留集** $B=\{s\in\{-,0\}\}$，无法判断的 $I_k^{?}$ 单列，用最好和最坏情形给出结论范围。
3. **议题占比** $m_{u,t}=\pi_{u,t}(I_k)$。**议题内目标占比** $p_{u,t}=\pi_{u,t}(A)/\pi_{u,t}(A\cup B)$。
4. **三个参照**：供给占比 p^{sup}（平台上符合条件的议题视频中 A 的比例）；平台平均曝光占比 $\bar p=\bar\pi(A)/\bar\pi(A\cup B)$，其中 $\bar\pi=\mathbb{E}_u\,\pi_u$；关闭个性化后的占比 p^{np}。
5. **观点偏斜**（茧房强度）

$$V_{u,t}=\operatorname{logit}p_{u,t}-\operatorname{logit}\bar p.$$

   $V=\log 2\approx 0.69$ 表示该用户看到目标叙事的几率是平台平均的 2 倍。以 $\bar p$ 为参照，V 衡量的是个性化造成的部分；相对供给的总偏斜见 4.2。
6. **用户状态平面** (m,V)：横轴是兴趣，纵轴是观点偏斜。
7. **策略** σ：用户在一段时间内执行的一组操作。记执行前后的变化 ΔV、$\Delta\log m$，以及保留集的保留系数 $\bar g(B)=\pi'(B)/\pi(B)$。**努力** E_σ 为操作次数。**持续时间** h_σ：停止后 ΔV 回到一半所需的步数。
8. **恒等式**：记 $\bar g(G)=\pi'(G)/\pi(G)$，则

$$\Delta V=\log\bar g(A)-\log\bar g(B),\qquad \Delta\log m=\log\big(p\,\bar g(A)+(1-p)\,\bar g(B)\big).$$

   v4 的目标减少 $\delta_T=1-\bar g(A)$、连带损失 $\delta_R=1-\bar g(B)$ 与这里的量一一对应，v4 的选择性 $S=1-\delta_R/\delta_T$ 作为辅助指标保留。

4.2 偏斜的三段分解

$$\underbrace{\operatorname{logit}p_u-\operatorname{logit}p^{\mathrm{sup}}}_{\text{用户看到的总偏斜}}=\underbrace{\operatorname{logit}\bar p-\operatorname{logit}p^{\mathrm{sup}}}_{\text{全局排序的放大}}+\underbrace{V_u}_{\text{个性化}}.$$

这是恒等式，在模拟中三项都能精确算出。它把"茧房来自平台排序、来自内容生态，还是来自个性化"变成可测的问题。思路与 Bakshy 等（Science 2015）把 Facebook 上跨立场新闻曝光分解为社交网络、排序算法和个人选择相同，这里用于推荐信息流，并且能在模拟中做精确的反事实。

4.3 命题

以下命题在 v4 的基础上改写为用户侧的量。证明简单，写入报告附录。

- **命题 0（类型与标签层面的操作）**：若一个操作让同一标签内所有视频的曝光乘以同一系数，则 ΔV 只取决于标签与属性的相关：

$$\Delta V = \log \frac{\sum_\ell w_\ell^A g_\ell}{\sum_\ell w_\ell^B g_\ell},$$

  w_ℓ^A、w_ℓ^B 是 A、B 的曝光在标签 ℓ 上的分布。若各标签内 A 的占比相同，$\Delta V = 0$。同理，只依赖类别分布的"茧房评估"对 V 不敏感。关闭整个议题时 $m \to 0$，V 不再有意义。

- **命题 1（过滤类操作）**：屏蔽被判为 A 的视频且不回填时，$\bar{g}(A) = 1 - \mathrm{TPR}_\pi$，$\bar{g}(B) = 1 - \mathrm{FPR}_\pi$（按曝光加权），因此

$$\Delta V = \log \frac{1 - \mathrm{TPR}_\pi}{1 - \mathrm{FPR}_\pi}, \qquad \Delta \log m = \log\big(1 - p\,\mathrm{TPR}_\pi - (1-p)\,\mathrm{FPR}_\pi\big).$$

  关键词、作者、相似度、LLM 判断都属于这一类，区别只在判断来源。

- **命题 2（反馈的一阶效应，对偶）**：点积打分、softmax 曝光 $\pi(i) \propto e^{\langle u, v_i\rangle/\tau}$。用户对视频 j 的一次反馈使 $u \leftarrow u + \eta v_j$（$\eta > 0$ 为正反馈，$\eta < 0$ 为"不感兴趣"）。记 $s_j(i) = \langle v_j, v_i\rangle$，$\bar{s}_j(G)$ 为 G 内按曝光加权的平均，$\bar{s}_j$ 为全体平均。一阶近似下

$$\Delta V \approx \frac{\eta}{\tau}\big[\bar{s}_j(A) - \bar{s}_j(B)\big] = \frac{\eta}{\tau} c_j, \qquad \Delta \log m \approx \frac{\eta}{\tau}\big[\bar{s}_j(I_k) - \bar{s}_j\big] = \frac{\eta}{\tau} t_j.$$

  c_j 是**属性对比**，t_j 是**话题对比**。η 的符号和大小由平台的实现决定，不由用户决定：试点中 OneRec 学到的"不感兴趣"相当于 $\eta > 0$。由此得到三点：

  1. *形成*：用户对 A 的正反馈多于对 B 的，V 的增长速度正比于属性对比与两者互动率之差。若所有视频的 $c \approx 0$，个性化不能产生观点偏斜，用户的反馈也不能精准消除它。形成与逃离由同一个量决定。
  2. *"不感兴趣"的汇率*：对 A 中视频点"不感兴趣"，每降低一单位 V，议题占比的对数要降低 t_a/c_a 单位。表示按话题组织时 $t \gg c$，代价很高。
  3. *正向替代*：对 B 中视频正反馈，$\Delta V < 0$ 而 $\Delta \log m > 0$，不损失议题。

- **命题 3（反馈强度的代价）**：累积强度为 κ 的"不感兴趣"使 $\pi^\kappa(i) \propto \pi(i) e^{-\kappa s_j(i)}$。只要倾斜后的 A 内平均相似度高于 B，p 随 κ 单调下降；但若议题外存在比议题内任何视频都更不相似的内容，$\kappa \to \infty$ 时 $m \to 0$。**反复点"不感兴趣"会改善议题内的构成，但代价是整个议题从信息流中消失。**这与 Kaplan 等（2026）在 TikTok 上观察到的现象一致，也能在真实模型上检验。

- **命题 4（察觉的样本量）**：用户侧工具从信息流中看到 n 条同议题视频，用查全率 α、误报率 β 的分类器判断属性，观测占比 $q = \beta + (\alpha - \beta)p$（Rogan & Gladen 1978 的校正）；再从"关闭个性化"模式中取 n_0 条作参照。单侧检验 $V \le 0$ 对 $V = v$，显著性 a、功效 $1-\gamma$ 时，取 $n_0 = n$ 需要

$$n \approx \frac{(z_a + z_\gamma)^2\,[q_u(1-q_u) + q_0(1-q_0)]}{(\alpha-\beta)^2\,(p_u - p_0)^2}.$$

  例：取 $\alpha = 0.8$、$\beta = 0.02$、$a = 0.05$、功效 0.8。按 LLM 试点，以偏概全叙事约占议题曝光的 1.8%；参照占比 $p_0 = 1.8\%$、偏斜为 2 倍几率时，$n \approx 2{,}600$ 条同议题视频，按 RecIF 用户议题占比的中位数 1.6% 换算约 16 万次曝光，是 RecIF 用户历史长度中位数（493）的约 330 倍；偏斜为 4 倍时仍需约 400 条（约 51 倍）。对冲突叙事这种常见属性（$p_0 \approx 41\%$），2 倍偏斜只需约 160 条。信息流的自相关会让所需样本更多。平台用曝光概率直接计算则不需要抽样。

- **结构性观察（持续性）**：只看最近 W 条历史的推荐器，改变历史的操作在之后 W 次同类互动后完全失效；只过滤输出的操作停用即失效。OneRec 条件推荐任务中每类行为最多保留 10 条，视频推荐任务最

多保留 512 条视频（第 7 节）。真实平台可能另存长期的负反馈列表，所以持续性要在每个推荐器上实测。

4.4 哪些来自已有研究，哪些是新的

内容	来源
茧房、过滤气泡的概念	Sunstein 2006；Pariser 2011；概念混乱的批评见 Michiels 等 2022、Bruns 2019
反馈回路造成同质化与偏好放大	Chaney 等 2018；Jiang 等 2019；Kalimeris 等 2021；Piao 等 2023
曝光的分解思路	Bakshy 等 2015（社交网络、排序、个人选择）
用户改变推荐结果的能力（可达性）	Dean 等 2020；Curmei 等 2021（单个物品、矩阵分解、不计连带损失）
误分类校正、预测增强推断	Rogan & Gladen 1978；Angelopoulos 等 2023
新： (m, V) 状态平面与"话题集中不等于茧房"的形式化	本研究
新： 形成与逃离由同一属性对比决定（命题 2 的对偶），以及"不感兴趣"的汇率、正向替代	本研究，在真实推荐器上检验
新： 观点层面的察觉样本量，及话题层面评估的盲区	本研究
新： 带议题保留约束和努力约束的"选择性可达性"，及最优逃离规划	本研究，推广 Dean 等的单物品可达性

5. 已有研究与空白

方向	代表研究	做到了什么	没做到什么
推荐系统中的茧房测量与模拟	Nguyen 等 2014；Piao 等 2023；Agent4Rec（Zhang 等 2024）；RecAgent（Wang 等）；Sukiennik 等 2025（短视频）；BEP（AAAI 2026）；Yang 等 2026（生成式推荐）	类别、标签或语义 ID 空间的集中度；LLM 模拟用户；生成式推荐中分词方式影响茧房	不测议题内观点；不区分兴趣与观点偏斜
观点层面的平台审计	Haroon 等 2023；Hosseinmardi 等 2024；Tomlein 等 2021、Srba 等 2023；Pecher 等 2026（TikTok 立场漂移）	政治、虚假信息话题中立场推荐的偏向；观看反方内容可"戳破"气泡；侧栏推荐约 30 个视频后"忘记"党派偏好	黑箱平台，无法分解机制；策略少；不计议题损失；不涉及中文日常议题
用户控制的效果	Mozilla 2022；Kaplan 等 2026；Wang 等 RecSys 2023；Vombatkere 等 2024	"不感兴趣"等按钮能减少多少相似内容；停止后会复发	话题或相似视频层面；不看议题内观点；不计连带损失
用户可控推荐与工具	UCRS（Wang 等 SIGIR 2022）；CIRS（Gao 等 TOIS 2023）；Compass（UIST 2026）；平台"茧房评估""一键破茧"（2025）	用户按类别或特征调整；系统侧破茧；按用户反思调整信息流	控制粒度停在类别、标签或主题
察觉与参照	Balancer（Munson 等 2013）；Hannak 等 2013（对照账号测个性化）；Karizat 等 2021（用户的算法民间理论）	向用户显示阅读的政治倾向能小幅改变行为；用对照账号作参照	没有观点层面察觉需要多少证据的分析
可达性理论	Dean 等 2020；Curmei 等 2021	用户能否通过改变评分让某物品被推荐	单个物品；没有"减少一类、保留另一类"的集合目标与代价

空白：没有研究在真实训练的推荐器上，把”日常议题内的观点茧房”与”兴趣集中”分开，同时回答它怎样形成、用户能否察觉、各种用户操作的代价与持续性，并用一个统一的机制（表示中的属性对比）解释这三者。国内对”信息茧房是否被夸大”也有争论：深圳大学 2025 年的报告基于问卷和账号测评认为担忧有所夸大，抖音称其算法已不依赖标签。这些判断都停在话题或主观感受层面，本研究在观点层面给出可检验的答案。

6. 研究设计

6.1 推荐器（模拟环境）

编号	推荐器	物品表示	历史	用途
R1	OneRec-1.7B / 8B，视频推荐任务	语义 ID，来自视频文本描述的 Qwen3-Embedding-8B 向量	约 500 条视频的序列，不带行为类型；目标是用户随后的视频	曝光的自我强化、搜索与插入类策略、持续性
R2	OneRec，条件推荐任务	同上	分栏：看完、点赞、关注、转发、不感兴趣，各约 10 条	反馈类策略
R3	在 RecIF 日志上训练的序列推荐模型（SASRec 结构，输入带行为类型），多任务输出看完、点赞、“不感兴趣”的概率，排序分数为各概率的加权和（与 X 开源代码的价值模型结构相同）；三种物品表示：仅 ID、仅内容（冻结的文本 embedding）、两者结合	ID / 内容 / 混合	可设定	隔离表示的作用，检验 H1b、H1c
R4	命题 2 的线性 softmax 模型，参数取自 R1–R3 测得的几何量	各推荐器的 embedding	无	理论预测与黑箱结果对照

每个推荐器都计算三个参照：用全体种子用户平均得到 $\bar{\pi}$；用空历史或通用历史得到 π^{np}；用议题语料的标签得到 p^{sup}。曝光分布用精确的序列概率（语义 ID 三层逐层计算）或大样本采样估计。

6.2 模拟用户

不手设机制参数。用户的反应模型从 RecIF 真实曝光与反馈中估计：

$$\operatorname{logit} P(y_{ui}=1) = a_u + b^{\top} x_i + \gamma_u \mathbb{1}[i \in I_k] + \theta_u \mathbb{1}[i \in A],$$

y 分别为看完、点赞、“不感兴趣”；$(a_u, \gamma_u, \theta_u)$ 是用户层面的随机效应，其分布由层次模型估计。θ_u 就是”用户对目标叙事的偏好”，它的均值和分散程度来自数据。不同类型的模拟用户（偏好 A、中性、偏好 B）取这个分布的分位数，而不是人为设定。

- 标签有误差会让 θ 被低估。用人工金标准样本估计分类器的混淆矩阵，在估计中校正，并做敏感性分析。
- 日志里的曝光不是随机的，估计会受选择偏差影响。用 KuaiRand 的随机曝光数据做方向检验（若议题样本足够）。
- 作为稳健性检验，再用两种用户模型重跑主要结果：OneRec 自带的反应预测任务（label_pred），以及基于描述阅读的 LLM 模拟用户（参考 Agent4Rec，用真实反应率校准）。

模拟流程：OneRec 的种子取基准测试集用户（公开的日志文件只含训练用户，测试用户只出现在基准文件中，未参与 OneRec 训练）；R3 的种子取我们自己划出的留出用户；每一步推荐器给出 π_t，抽取一条视频，用户按反应模型产生反馈，写回历史；每隔若干步精确计算 (m_t, V_t)。

6.3 内容与标签

- **议题**：主议题为婚恋与家庭（RecIF 中关键词候选约 26 万条视频，占全部曝光的 2.0%）；第二议题取组员已定的育儿议题；彩礼留作检验泛化的留出议题。
- **属性**：按 LLM 试点（第 7 节）建议：主属性为（a）把群体（而非单个人物）描绘为负面、或把个案归结为某一性别普遍特征的叙事，约占议题曝光的 1.8%；对照属性为（c）以婚恋或家庭冲突为核心的叙事，约 41%。两者构成从"立场型"到"内容型"的梯度，用来检验 H1b 的推论。（b）对婚姻的消极态度在试点中与冲突叙事混淆，改为显式立场定义（"婚姻不值得""劝人别结婚"）后作为可选的第三属性。
- **标注**：开源 LLM 标注全部议题候选；两名组员独立标注每个属性约 400 条金标准（按曝光加权抽样），计算 Krippendorff's α。总体量用预测增强推断（PPI）校正；用户反应模型用混淆矩阵校正。
- **描述的信息损失**：RecIF 的视频描述由模型生成，会把语气改成中性转述。在 ShortVideo（有原始语音转写和视频）上比较"按转写判定"与"按生成描述判定"的属性，量化损失，作为标签效度的边界。

6.4 实验

实验	内容	对应
E1 真实日志	属性流行度；按属性的互动率；供给占比与曝光占比之差（H1a）；用户间离散度及时间匹配的置换基准（H1d）	RQ1
E2 表示几何	各推荐器的属性对比 $\boldsymbol{c}$ 与话题对比 $\boldsymbol{t}$，带置信区间	RQ1、RQ3
E3 形成	三类模拟用户在 R1–R3 上的 (m_t, V_t) 轨迹；三段分解；与 R4 的预测比较；用模拟人群的 V 分布对照 E1 的真实离散度，检验模拟的效度	RQ1
E4 察觉	命题 4 的样本量曲线；在模拟轨迹上运行序贯检验，得到察觉延迟；实现一个"内容类型分布"式的茧房评估，测它对 V 的敏感度	RQ2
E5 逃离	从 E3 的终点出发，执行 S1–S12；记录 ΔV、$\Delta \log m$、$\bar{g}(B)$、议题外分布的变化、努力；停止后再跑自然行为，测持续时间	RQ3
E6 最优规划	把逃离写成约束优化：输入为当前历史、可用操作（对某条视频反馈、搜索并观看、删除某条历史）、努力上限 $E_{\max}$ 和议题保留下限 $\Delta \log m \geq -\varepsilon$，输出使 V 最小的操作序列。每一步先用命题 2 的一阶近似从候选操作中筛出前 K 个，再用推荐器精确评估，复杂度约为 $O(E_{\max} \cdot K \cdot C)$，$C$ 为一次精确评估的代价。结果作为任何用户策略的上界，与现实策略的差距说明一个会规划的助手工具能带来多少改进	RQ3
E7 稳健性	第二议题、留出议题、第二属性；OneRec-8B；不同用户模型	全部

"不感兴趣"在不同系统里的实现不同，所以 S1 分三种实现比较：（i）只从日志中学习（R2 的"不感兴趣"栏；R3 只把它当作输入），（ii）显式的"不推荐"训练目标（Wang 等 RecSys 2023），（iii）排序时按相似度降权（价值模型中"不感兴趣"概率的权重是平台的设计参数，作为实验条件扫描并报告曲线，而不是假设一个值）。

用户策略：S1 对 A 点"不感兴趣"；S2 快速划过 A（不看完）；S3 看完或点赞 B；S4 主动搜索并观看 B；S5 删除历史中的 A；S6 关键词屏蔽；S7 关闭议题标签；S8 关闭个性化；S9 重置推荐；S10 外部 LLM 过滤；S11 平台式"一键破茧"（按内容类型打散）；S12 不做任何事（对照）。作者屏蔽需要作者 ID，RecIF 不提供，只在 KuaiRand 上作补充。

6.5 交付物

最终报告；状态平面上的形成轨迹与策略前沿图；一份面向用户的”观点曝光报告”设计（沿用组员的曝光报告流程，加入参照和置信区间），用于说明察觉工具应当显示什么、不应声称什么。课程不评代码，代码和数据处理脚本照常公开以便复核。

7. 可行性验证（已完成部分）

详见 v5 可行性记录。数字都来自实际运行；LLM 标签只是试点，不是金标准。

检查	结果	对计划的影响
真实曝光的结构	婚恋家庭议题占全部 7,567 万次曝光的 2.0%；每人议题曝光中位数 8 次；被曝光 ≥20 次的议题视频约 1 万条	个人层面的 V 在模拟中精确计算，真实日志做总体检验；按 ID 学习的模型只覆盖 1–4 万条议题视频
用户间离散度	关键词代理叙事在每人议题曝光中的占比，离散系数是随机基准 95% 分位的 4 倍	支持 H1d；正式分析用时间匹配的置换基准
LLM 标注	1,800 条全部输出合法结果，约 2 分钟；按曝光加权，(a) 以偏概全 1.8%、(b) 婚姻消极 6.1%、(c) 冲突叙事 41.5%；(a) 有把单个反派判为群体的误报，(b) 与 (c) 混淆	主属性 (a)、对照 (c)；收紧定义，人工金标准估计误报
互动差异	(c) 看完率高 3.9 个百分点；(a) 点赞率与其他视频相近；三种属性在已曝光视频中的曝光份额都不高于均匀抽样的份额	H1a 改为双向检验
OneRec 可用性	不开思考模式时 99.9% 输出合法语义 ID；精确打分 2,000 条候选用时 1.4 秒（条件推荐）或 7.6 秒（视频推荐）；真实的下一条视频在 2,000 条随机视频中排第 1	可作模拟推荐器，用精确概率计算 V
OneRec 话题响应	“看完”栏换成 10 条议题视频，议题占比 2.8% → 5.7%；视频推荐历史末尾加 20 条议题视频，2.3% → 9.6%	形成实验可行
OneRec 的”不感兴趣”	把 10 条议题视频放进”不感兴趣”栏，议题占比反而**升高** 1.2 个百分点（标准误 0.09），40 人全部升高。换成”不喜欢””屏蔽”标题效果相同，约为中性标题的 78%：模型主要把上下文里的视频当作兴趣线索。日志检验不支持”曝光选择”这一解释	S1 分三种实现比较；“只从日志学到的’不感兴趣’起反作用”是 RQ3 的第一个发现
OneRec 议题内的区分	往”看完”栏注入 10 条以偏概全视频，比注入同形式的其他议题视频，推荐中这类叙事的对数几率高 1.13（标准误 0.12，约 3 倍）；排除近似重复后 1.05；冲突叙事 0.65；随机假属性 −0.22（不显著）。对以偏概全视频点”不感兴趣”，这类叙事的几率反而高 0.63	个性化能在议题内放大叙事，形成实验有实质内容；“不感兴趣”在观点层面同样反向；H1b 的属性排序改为不预设方向
内容表示的属性对比	在 OneRec 语义 ID 所依据的 Qwen3-Embedding-8B 中，以偏概全的平均相似度对比只有话题对比的 0.15（随机对照 0.10），但线性探针 AUC 0.88（对照 0.55）；冲突叙事 0.59、AUC 0.97	平均相似度与推荐器的实际响应排序不一致，需要用 R4 与 R1–R3 对照，不能只看 embedding
算力与环境	8×A6000 空闲；vLLM 0.11 需固定 transformers 4.57；服务器访问 Hugging Face 不稳定，ModelScope 可用	无卡点

8. 工作包与分工

工作包	内容	负责
WP0 理论	定义、命题与证明，预登记假设	Li Yitong
WP1 标签	属性定义与标注规范、LLM 标注、金标准、PPI 校正、描述损失实验	Fu Yitong、Wang Junbo、Zhao Dingcheng
WP2 真实日志	E1、反应模型估计	Xu Ruicong、Li Yitong

工作包	内容	负责
WP3 推荐器	R1–R4、参照分布、表示几何（E2）	Li Yitong
WP4 模拟与形成	模拟器、E3、效度检验	Li Yitong、Xu Ruicong
WP5 察觉	E4、观点曝光报告的设计	Wang Junbo、Zhao Dingcheng
WP6 逃离	E5、E6、持续性	Li Yitong、Zhao Dingcheng
WP7 综合	报告、局限与伦理、演示	Fu Yitong 统筹，全组

组员已有的工作都能直接接入：标注模板和一致性检查进入 WP1；曝光报告流程进入 WP5；五种策略的简易仿真作为 S1–S12 的原型；KuaiRand 轨迹整理进入 WP2 的稳健性检验。

9. 资源档位

档位	内容	资源
理想	两个议题、三种属性；R1（1.7B 与 8B）、R2、R3 三种表示、R4；每种模拟用户 1,000 个种子；全部 12 种策略和最优规划；三种用户模型	8×A6000 约数百 GPU 小时；磁盘约 150GB；开源 LLM 标注全部候选，前沿 API 抽检约数千条
平衡（建议）	主议题两种属性，第二议题一种；R1（1.7B）、R2、R3 三种表示、R4；每类 300 个种子；全部策略；最优规划只在 R3 上做	2–4 张 A6000；磁盘约 100GB
最低	主议题一种属性；R2 与 R3（ID、内容两种）；每类 100 个种子；S1、S3、S5、S7、S8、S10	1–2 张 A6000

10. 需要你决策的事项

编号	事项	建议
D1	主属性	(a) 性别以偏概全叙事为主，(c) 冲突叙事为对照，(b) 改写定义后可选（理由见 6.3 与第 7 节）
D2	议题	婚恋与家庭为主；第二议题用组员已定的育儿议题；彩礼留出
D3	LLM	开源模型做全部标注（可复现、无费用）；前沿 API 只做抽检和上界，需要可用账号
D4	人工标注	每个属性约 400 条，双人独立标注
D5	算力与磁盘	服务器 tyu-g1；约 100–150GB
D6	OneRec 规模	1.7B 为主，8B 做稳健性
D7	与组员方案的衔接	用 v5 替换组内的研究问题，组员的模块按第 8 节接入

11. 风险与卡点

风险	影响	应对
目标叙事在议题内很少（LLM 试点约 1.8%，明显标签词只占 0.16%），且 LLM 会把单个反派误判为”推广到群体”	真实日志中 A 的样本少，θ 估计不稳；标签有系统性误报	对 26 万条候选全部标注，A 约有数千条；收紧定义并用人工金标准估计误报率；对照属性 (c) 提供统计功效；模拟中用精确概率而非抽样
模拟用户不像真实用户	结论只对模型成立	反应模型从真实数据估计；用真实日志的用户间离散度检验模拟；三种用户模型对照
OneRec 不是快手线上系统	外推有限	结论表述为”这类推荐器”；同时用 R3 和真实日志；结果按推荐器分别报告

风险	影响	应对
生成描述抹平语气	标签低估叙事	ShortVideo 上量化损失；属性定义为”依据描述可判定”
物品 ID 模型对冷门视频学不到表示	R3 中 A 的覆盖不足	只在有足够互动的视频上比较；报告覆盖率；混合表示兜底
真实平台”不感兴趣”的实现不公开	无法断言线上按钮的效果	三种实现作为情境分别报告；结论表述为”在何种实现下”，并与 Kaplan 等、Mozilla 的平台审计结果对照

12. 与历史版本的关系

- v1 最初的”镜子—按钮—代价”设想（察觉、操作、代价）就是 v5 的三个子问题；v5 补上了 v1 缺少的严格定义、真实推荐器和不手设参数的用户模型。
- v4 的定义和命题 0–3 保留，改写为用户状态 (m, V) 上的量；v4 的”表示决定精准度”成为解释形成和逃离的统一机制，不再是研究问题本身。v4 的 RQ1（能否识别属性）降为方法部分的测量工具。
- 对照课程要求：主要形式是 Simulation / Modeling（模拟的系统、状态、规则、时间步与输出指标见第 4、6 节），辅以 Data Analysis（真实日志的描述统计与估计）和一个算法问题（E6 的约束优化）。研究问题是可测量的计算问题，而不是产品需求。