保留话题，拓宽视角

理解短视频信息茧房，支持用户主动调整信息流

Fu Yitong	Li Yitong	Wang Junbo	Xu Ruicong	Zhao Dingcheng
3036482371	3036289377	3036482682	3036291100	3036292283

1. 问题与方案概念

一个经常看育儿视频的人，可能反复听到“只有严格管教才能培养出优秀孩子”。他的信息流里仍有美食、音乐和旅行，按内容类别统计，看起来并不单一。但在育儿这个议题内，同一种解释可能长期占据主导。他希望少看武断的概括，同时继续了解管教方法，而“不感兴趣”按钮很难表达这种区别。

本项目的问题是：短视频用户如何发现日常议题中持续存在的观点与理由的局限，并在保留所需信息的前提下调整自己的曝光？

我们关注中文短视频中的信息茧房风险：在育儿、婚恋和职业选择等议题内，推荐与用户反馈可能反复强化有限的观点和理由。英文采用 **filter bubbles**，突出个性化推荐这一情境；观点曝光是具体测量对象，不等于已经证明算法因果或危害。兴趣集中不一定有害，也不应强行平衡正反方。真正值得关注的是用户未察觉、或难以按自身意愿改变的选择性呈现。

方案包括三个部分。首先，用曝光报告展示反复出现的主张、理由与来源，并提供可回看的例子。其次，通过目标确认明确用户想减少、保留或进一步了解什么。最后，比较并复查调整办法，分析它们能否达到目标，以及需要多少持续操作。例如，用户可以要求减少“严格管教是唯一有效办法”的表达，同时保留具体建议和不同做法的解释。

我们将在至少两个议题上共同开发方法，再用一个未参与开发的议题评价适用性。主要成果是带证据的报告设计、干预策略比较和动态仿真；条件允许时用小型工具演示，不要求完成一个 app。研究重点是曝光与控制，不直接测量用户信念或生活质量的改变。

2. Computing 与 data science 方法

本项目属于数据分析、算法设计与仿真建模相结合的 **hybrid project**。技术重点是：在保留有用信息的约束下选择调整办法，再分析它们在“推荐—反馈”循环中的效果。已有方法适用时直接采用，不要求发明新算法。

理解内容

先用关键词和语义检索寻找相关视频，再识别具体命题、发言者立场、理由和视频中可见的依据。大语言模型（LLM）可分析标题与转录；涉及对话、字幕或画面语境时，视觉语言模型（VLM）可结合片段与画面进行判断。剧情角色的一句台词不能直接算作作者的观点。

模型输出须附依据片段，并允许回答“无法判断”。两名成员将独立标注评价样本，处理或保留分歧，再检查模型错误。通过比较标题、加入转录和加入音画三种输入，判断额外语境何时有帮助。检索也需要评价，包括初次搜索遗漏的相关内容。

描述曝光

针对具体议题，统计立场分布、重复理由、同一来源材料的反复出现及时间变化。参照可以是用户过去的信息流，也可以是有出处的相关论据集合，但两者都不自动代表“正确分布”。报告会展示缺失材料和不确定标签，不把所有现象压成一个信息茧房分数。

这里必须区分内容集合与个人曝光记录。只有日志中存在足够相关观察时，才生成个人时序报告；否则说明覆盖不足，并用明确标注的构造序列检验报告方法。

比较调整办法

控制环节的输入是用户确认的“减少什么、保留什么、补充什么”及允许采取的操作。我们将比较不干预、整话题过滤、针对性负反馈、选择性过滤与有来源的信息补充，以及主动搜索或关注。比较时会区分平台自带操作与拟议外部工具提供的过滤、信息补充功能。

采用简单的约束选择方法：先排除会删去过多所需信息的策略，再比较剩余方案中的不希望看到的曝光量、信息保留、新增理由和操作负担。语义相似度可以帮助检索，但不能单独判断材料是否提供了新的理由。LLM 助手可澄清需求、调用搜索和分析工具，具体统计与约束判断仍由可复查的程序完成。

检验动态反馈

仿真分别表示内容池、推荐器、用户和干预策略。每一步中，推荐器选择内容，用户作出反应，平台更新行为历史，再产生下一轮推荐。用户容易停留观看的内容，与他希望调整后的信息流，分别建模。

我们将比较透明的规则用户、数据驱动用户和 LLM 用户。一个值得检验的方案是：用模型理解内容含义，再结合统计模型预测可观察行为。有配对内容与日志时，先用留出的真实记录检验行为预测；能说出合理理由，不等于行为真实。如果更复杂的用户模型缺乏依据，仍保留简单仿真来分析机制。

实验将比较持续干预与停止干预，并改变推荐记忆、探索和负反馈响应等假设。记录目标是否达到、所需曝光步数、有用信息损失、操作次数，以及不希望看到的模式是否再次出现。通过重复运行检验结论对模型假设的敏感性；仿真不代表真实平台的完整复刻。

3. 相关研究与本项目的切入点

参与行为与用户意愿可能不一致。 Milli 等 [1] 在 Twitter 政治内容研究中发现，按参与度排序与用户自述偏好并不一致；按自述偏好排序又可能强化与自身立场一致的内容。这说明需要区分“吸引注意”与“用户想要”，也不能把用户控制当成自动有效的解决办法。Vera 和 Ghosh [2] 通过对 14 位 TikTok 用户的访谈，记录了不想要的推荐及清除这些内容的尝试，为本项目的生活情境提供依据，但不能据此推断中国用户的发生率。

观点分析需要超出类别统计。 Pecher 等 [3] 的 TikTok 审计区分了话题变化与立场变化，因此“研究同一话题里的观点”本身并不是空白。Draws 等 [4] 在搜索结果研究中从立场和背后的论证逻辑理解观点多样性。我们借用这种区分，并面对短视频中的角色、语境缺失和重复故事等判断困难。

用户控制已有成熟方法。 Wang 等的 UCRS [5] 允许用户通过特征层面的控制影响推荐。本项目面对的是用户通常无法修改平台模型的情况：如何表达“继续了解这个议题，但调整某类表达或补充某种理由”，再通过手边的操作实现？X 的公开推荐代码 [6] 提供了可检查的过滤和评分机制，但不能证明中国短视频平台采用相同规则。

公开数据与仿真支持部分验证。 Shang 等发布的 ShortVideo 数据集 [7] 将内容与行为联系起来；KuaiRand [8] 提供时序互动和随机曝光视频，可用于内容分析及行为检验，但都没有记录用户经过思考后确认的调整目标。SimTok [9] 展示了由 LLM 用户读取视频文本描述、与推荐器反复互动的模拟方法。Yoon 等 [10] 则说明，模拟偏好和反馈需要独立对照真人数据。因此，我们会把用户模型是否可信与干预是否有效分开评价。

这些研究为我们留下了一个具体问题：能否从用户侧识别生活议题中反复出现的理由，把具体调整目标转化为可用操作，并比较信息损失和持续维护的代价？ 本项目将在多个议题、内容判断不完整和平台权限有限的条件下研究这一问题，而不是提出新的推荐算法。

4. 可行性、局限与伦理

我们已经取得公开短视频内容与互动数据，检查了视频与转录的配对，并完成语义检索和用户响应模型的初步运行检查。这些说明数据入口和基础运行路径可用，不代表内容判断已经准确或仿真已经真实。

试标结果将指导样本选择，以覆盖重要情境并评价错误。我们会复用预训练模型和成熟统计方法。较大模型的推理需要合适算力；若资源不可得或效果不佳，仍可用人工核查的内容分析，并在透明仿真中展示控制逻辑。报告会区分已实现部分与仍停留在设计层面的部分。

主要局限是视频语境不全、个人轨迹稀疏、平台响应未知。负反馈前后的日志变化首先作为关联，不直接解释为因果效果；仿真结论也保留其假设条件。接触更多观点不证明判断更好，过滤不喜欢的观点还可能进一步缩窄信息流。因此，我们会展示取舍，也不会在证据强弱不同的情况下把相反说法视为同样可信。

核心工作使用公开研究数据与模拟用户。离线实验的调整目标将作为测试情境预先设定，不把它们当作匿名日志中真实用户的意愿。我们将遵守数据使用条款，不识别个人，在共享输出和示例中去除不必要的个人信息。若使用外部 AI 服务，需符合数据允许的用途，并避免发送可识别的个人历史。真人测试属于可选部分；招募前会确认适用的课程或学校要求并取得知情同意。核心研究不需要自动操作真实账号或实施线上平台干预。

5. 时间安排与成员分工

以下日期依据课程 guideline，最终以 Moodle 公告为准。

时间（**2026** 年）	阶段成果	负责人
10 月 4 日	提交计划，确认问题与职责	Li Yitong；全组
10 月 5–11 日	选择议题、检查数据、试标并确定评价方法	Fu Yitong、 Xu Ruicong、 Zhao Dingcheng
10 月 12–18 日	评价内容理解，形成曝光报告和控制比较初稿	Zhao Dingcheng、 Wang Junbo、 Li Yitong
10 月 19–24 日	准备贯通案例和初步仿真，参加期中会议	Xu Ruicong、 Li Yitong；全组
10 月 25–31 日	比较干预及不同假设，在留出议题上评价	Li Yitong、 Xu Ruicong、 Zhao Dingcheng
11 月 1–8 日	整理结果和报告初稿；11 月 4 日提交个人进度日志	全组，Wang Junbo 协调整合
11 月 9–15 日	复核论证与引用，提交报告和个人反思	全组
11 月 16–26 日	排练，并按课程指定日期展示	Wang Junbo；全组

成员	主要职责
Fu Yitong	问题定义、文献综合、观点标注与内容判断错误分析
Li Yitong	技术统筹、约束干预算法、推荐器与用户动态仿真、敏感性实验
Wang Junbo	用户调整目标、曝光报告与控制流程设计、独立标注和报告编辑
Xu Ruicong	数据准备、轨迹覆盖、行为建模与模拟用户的统计评价
Zhao Dingcheng	语义检索、LLM/VLM 内容分析、证据核查与跨议题评价

Fu Yitong 与 Wang Junbo 将和 Zhao Dingcheng 共同制定标注规范，再独立标注评价样本，并一起复核分歧。每位成员负责撰写自己的实质性章节，并复核另一位成员的工作。每周会议检查已取得的证据、尚缺条件和排期调整。

参考文献

[1] Milli, S., Carroll, M., Wang, Y., Pandey, S., Zhao, S., & Dragan, A. D. (2024). *Engagement, User Satisfaction, and the Amplification of Divisive Content on Social Media*. arXiv:2305.16941, version 6.

[2] Vera, J. A., & Ghosh, S. (2025). *"They've Over-Emphasized That One Search": Controlling Unwanted Content on TikTok's For You Page*. arXiv:2504.13895.

[3] Pecher, B., et al. (2026). *Algorithmic Audit of Personalisation Drift in Polarising Topics on TikTok*. UMAP 2026.

[4] Draws, T., et al. (2023). *Viewpoint Diversity in Search Results*. ECIR 2023, pp. 279–297. doi:10.1007/978-3-031-28244-7_18.

[5] Wang, W., Feng, F., Nie, L., & Chua, T.-S. (2022). *User-Controllable Recommendation Against Filter Bubbles*. SIGIR 2022, pp. 1251–1261. doi:10.1145/3477495.3532075.

[6] xAI. (2026). *x-algorithm* [Source code, commit b79b947].

[7] Shang, Y., Gao, C., Li, N., & Li, Y. (2025). *A Large-scale Dataset with Behavior, Attributes, and Content of Mobile Short-video Platform*. WWW Companion 2025, pp. 793–796.

[8] Gao, C., et al. (2022). *KuaiRand: An Unbiased Sequential Recommendation Dataset with Randomly Exposed Videos*. CIKM 2022, pp. 3953–3957. doi:10.1145/3511808.3557624.

[9] Sukiennik, N., Wang, H., Zeng, Z., Gao, C., & Li, Y. (2025). *SimTok: Simulating Filter Bubble on Short-video Recommender System with Large Language Model Agents*. arXiv:2504.08742.

[10] Yoon, S., He, Z., Echterhoff, J. M., & McAuley, J. (2024). *Evaluating Large Language Models as Generative User Simulators for Conversational Recommendation*. NAACL 2024, pp. 1490–1504.