保留话题，拓宽视角

理解短视频信息茧房，支持用户主动调整信息流

Fu Yitong	Li Yitong	Wang Junbo	Xu Ruicong	Zhao Dingcheng
3036482371	3036289377	3036482682	3036291100	3036292283

1. 问题与方案概念

一个经常看育儿视频的人，可能反复听到“只有严格管教才能培养出优秀孩子”。他的信息流里仍有美食、音乐和旅行，按内容类别统计，看起来并不单一。但在育儿这个议题内，同一种解释可能长期占据主导。他希望少看武断的概括，同时继续了解管教方法，而“不感兴趣”按钮很难表达这种区别。

本项目的问题是：短视频用户如何发现日常议题中持续存在的观点与理由的局限，并在保留所需信息的前提下调整自己的曝光？

我们关注中文短视频中的信息茧房风险：在育儿、婚恋和职业选择等议题内，推荐与用户反馈可能反复强化有限的观点和理由。英文采用 **filter bubbles**，突出个性化推荐这一情境；观点曝光是具体测量对象，不等于已经证明算法因果或危害。兴趣集中不一定有害，也不应强行平衡正反方。真正值得关注的是用户未察觉、或难以按自身意愿改变的选择性呈现。

方案包括三个部分。首先，用曝光报告展示反复出现的主张、理由与来源，并提供可回看的例子。其次，通过目标确认明确用户想减少、保留或进一步了解什么。最后，比较并复查调整办法，分析它们能否达到目标，以及需要多少持续操作。例如，用户可以要求减少“严格管教是唯一有效办法”的表达，同时保留具体建议和不同做法的解释。

用户未必知道自己遗漏了什么。因此，报告也会对照有出处的议题语料中可找到的理由，并提出供用户确认的调整目标。这份语料只是有限参照，不代表议题的全部观点，也不自动意味着正反方均衡。

我们将在至少两个议题上共同开发方法，再用一个未参与开发的议题评价适用性。主要成果是带证据的报告设计、干预策略比较和动态仿真；条件允许时用小型工具演示，不要求完成一个 app。研究重点是曝光与控制，不直接测量用户信念或生活质量的改变。

2. 计算与数据科学方法

本混合型项目用数据分析描述用户接触的信息，用算法设计在信息保留与操作成本约束下选择行动，再用仿真建模检验这些行动如何影响后续推荐。适用时直接复用成熟方法。

数据分析：测量观点曝光

工具只能看到截至步骤 t 可获得的内容与互动记录 $o_{\le t}$，不能访问平台内部状态。先用关键词和语义检索，再由大语言模型（LLM）或视觉语言模型（VLM）分析提取命题、立场、理由和来源标识，并附依据文本或时间戳。分析流程生成曝光摘要：

$$\hat{e}_t = \Phi(o_{\le t}) = (p_t, \mathbf{r}_t, d_t, u_t).$$

其中，p_t 是针对明确命题的可判定曝光立场分布，$\mathbf{r}_t$ 表示理由覆盖，d_t 表示来源重复，u_t 是未知标签比例。滑动窗口跟踪集中程度与变化。Shannon 熵 $H(p_t) = -\sum_k p_{t,k} \log p_{t,k}$ 用于衡量集中程度，越低表示曝光越集中在少数立场。Jensen–Shannon 散度 $\mathrm{JS}(p_t, q)$ 衡量与明确参照 q（如过去曝光）的差异。两者都不直接证明伤害，也不意味着均匀曝光最好。

独立双人标注、precision/recall 及留出议题用于检验测量质量。比较只看标题、加入转录和加入视觉语境的分析，检查更多模态能否减少把角色对白误当作者观点等错误。稀疏轨迹不评分。标注分歧保留用于错误分析；为未知内容赋予不同的合理标签，检查结论是否改变，而不默认已标注子集代表整个信息流。

算法设计：选择干预策略

策略（行动选择规则）根据曝光摘要、已确认的“减少—保留—探索”目标 g 和剩余预算 b_t，选择 $a_t = \pi(\hat{e}_t, g, b_t)$。在评价期 T 内比较允许的策略：

$$\min_{\pi \in \Pi_{\text{user}}} \mathbb{E}_\pi\left[\sum_{t=1}^{T} \ell(\hat{e}_t, g)\right] \quad \text{s. t.} \quad \mathbb{E}_\pi[C_T] \le B, \quad \mathbb{E}_\pi[R_T] \ge \rho.$$

Π_{user} 为允许的策略集合，期望对随机推荐与反应取平均。损失 ℓ 衡量目标偏离；C_T 为操作成本，R_T 为相对不干预时的信息保留程度。预算 B、最低保留要求 ρ 和测量规则由测试情境预先设定或用户确认。未知内容和空信息流不能被计为成功。以育儿为例，损失可衡量目标概括性说法的曝光，保留程度则跟踪实用建议及不同解释。新增理由依据有出处的来源集合评价，不能用模型生成的断言代替。

枚举不干预、话题过滤、负反馈、选择性过滤与补充、搜索 / 关注等策略，通过下文的仿真估计结果，再排除违反估计约束的候选；无可行方案时明确报告。结果已估计后，选择成本随候选数线性增长。比较将检验选择性调整能否比过滤整个话题保留更多所需信息，以及为此付出的代价。平台操作与外部工具功能分别处理。这里比较有限候选，不声称求得全局最优策略。

仿真建模：检验推荐—反馈循环

用 s_t 表示推荐历史和用户行为状态。在步骤 t，推荐器 $\mathcal{R}$ 生成曝光 x_t，用户模型 $\mathcal{U}$ 生成反馈 y_t，所选操作 a_t 进入状态更新规则 $\mathcal{F}$：

$$x_t \sim \mathcal{R}(\cdot \mid s_t), \quad y_t \sim \mathcal{U}(\cdot \mid x_t, s_t), \quad s_{t+1} \sim \mathcal{F}(\cdot \mid s_t, x_t, y_t, a_t).$$

这是仿真抽象，不是已观测到的平台模型；观看倾向与调整目标分别表示。推荐器根据内容相关性和历史反馈排序，加入探索及记忆衰减；观看和负反馈信号更新后续排序。透明机制作为基线，与基于互动轨迹训练的模型比较。比较规则、数据驱动、LLM 和混合用户，通过可获得的留出日志检验行为预测，包括概率校准，并检查更换用户模型是否会改变哪种干预表现最好。用户可能仍会观看令自己不快的视频，却希望减少同类推荐，模型需要容纳这种冲突。策略只能读取可观察记录，不能读取隐藏偏好或推荐器参数。

以匹配初始状态和多个随机种子比较目标达到、信息损失、操作成本及复发。分别测试持续干预、停止干预和恢复此前观看行为。均值同时报告跨次运行的波动和约束违反频率，避免平均表现掩盖结果的不可靠性。改变模型参数和标签错误检验稳健性；模拟效果不能直接证明真实平台效果。

3. 相关研究与本项目的切入点

参与行为与用户意愿可能不一致。 Milli 等 [1] 在 Twitter 政治内容研究中发现，按参与度排序与用户自述偏好并不一致；按自述偏好排序又可能强化与自身立场一致的内容。Vera 和 Ghosh [2] 访谈了 14 位 TikTok 用户，记录不想要的推荐及清除尝试。这些研究支持区分注意力与经过确认的目标，但不能据此推断中国用户的发生率。

观点分析需要超出类别统计。 Pecher 等 [3] 的 TikTok 审计区分话题变化与立场变化，因此同题观点分析本身并不是空白。Draws 等 [4] 在搜索结果研究中同时考察立场和论证逻辑，支持我们分析理由及观点，并处理短视频中角色、语境缺失等额外困难。

控制及其持续性已有研究。 Wang 等的 UCRS [5] 提供特征层面的推荐控制。Kaplan 等 [6] 用受控 TikTok 账号比较划走与“不感兴趣”，并检验恢复观看目标话题后的复发。Compass [7] 在 YouTube Shorts 中支持持续反思与细化偏好，结合模拟互动、直接过滤和内容补充，开展了 15 人、十天的实地研究。我们可以借鉴这些方法，重点联合评价同一议题内的主张与理由曝光、信息保留及持续操作成本。X 的公开代码 [8] 提供可检查的过滤和评分机制，不代表中国平台的实际规则。

数据与仿真支持部分验证。 ShortVideo [9] 联系内容与行为；KuaiRand [10] 提供互动序列和随机曝光视频，但两者都没有记录反思目标。SimTok [11] 展示了 LLM 用户读取视频描述、与推荐器循环互动的方法。Yoon 等 [12] 对照真人数据评价模拟偏好与反馈，支持我们独立评价用户模型。平台审计用于指导实验条件，不直接提供可跨平台套用的效果量。

本项目将这些方向结合起来：用户能否减少特定主张或探索缺失理由，同时保留同一议题的有用信息，为此需要付出多少持续操作？ 我们将在多个议题、内容判断不完整和平台权限有限的条件下研究这一问题。贡献在于对这个综合问题开展带证据的评价。

4. 可行性、局限与伦理

我们需要可理解的内容和互动轨迹。目前已取得 ShortVideo 样本、KuaiRand-1K/Pure 日志及补充标题与类别。八组 ShortVideo 视频与转录文件已取得，视频可解码；预训练语义检索和未训练的用户响应网络也已运行。这些说明入口和基础运行路径可用，不代表转录准确、模型可信或轨迹完整。ShortVideo 的抽样轨迹可能不连续，内容覆盖与轨迹覆盖需要分别检查。KuaiRand 的随机曝光来自有限视频池，不能当作关闭个性化后的完整信息流。

下一步用试检索和独立标注指导议题选择、样本量及错误分析，评价预训练 LLM/VLM 的内容判断，以及规则、学习和 LLM 用户模型。扩大规模前先测小批推理的资源需求。组件验证失败或超出可用资源时，采用人工核验内容或透明的规则仿真，并说明能力损失。报告区分已实现、已验证及仍待实施的部分。

语境缺失或表达不清时保留未知标签，用视觉核查和不同的合理标签检验影响。轨迹能否支持议题报告由覆盖程度和不确定性决定。平台响应未知，通过敏感性实验处理。负反馈关联不等于因果效果，模拟改善也不能证明真实平台效果或信念变化。接触更多观点不证明判断更好；选择性过滤还可能进一步缩窄信息流。我们会展示这些取舍，并保留证据质量的区别。

核心使用公开研究数据与模拟用户。目标是明确的测试情境，不冒充匿名日志中真实用户的意愿。遵守数据条款，不尝试重新识别个人，减少示例中的个人信息，不向外部 AI 服务上传个人观看历史。公开视频材料送至外部服务前，也需检查允许用途和个人信息。标注者可以跳过令人不适的内容。可选真人测试需知情同意，并确认适用的课程或学校要求；核心实验在线下进行。

5. 时间安排与成员分工

以下日期依据课程 guideline，最终以 Moodle 公告为准。

时间（**2026** 年）	阶段成果	负责人
10 月 5–11 日	选择议题、检查数据、独立试标并确定评价方法	Fu Yitong、Wang Junbo
10 月 12–18 日	评价内容理解，形成曝光报告和控制比较初稿	Zhao Dingcheng、Wang Junbo、Li Yitong
10 月 19–24 日	19 日前备好贯通案例和初步仿真；20–24 日期中会议	Xu Ruicong、Li Yitong；全组
10 月 25–31 日	比较干预及不同假设，在留出议题上评价	Li Yitong、Xu Ruicong、Zhao Dingcheng
11 月 1–8 日	整理结果和报告初稿；11 月 4 日提交个人进度日志	全组，Wang Junbo 协调整合
11 月 9–15 日	复核论证与引用，提交报告和个人反思	全组
11 月 16–26 日	排练，并按课程指定日期展示	Wang Junbo；全组

成员	主要职责
Fu Yitong	问题定义、文献综合、观点标注与内容判断错误分析
Li Yitong	技术统筹、约束干预算法、推荐器与用户动态仿真、敏感性实验
Wang Junbo	用户调整目标、曝光报告与控制流程设计、独立标注和报告编辑
Xu Ruicong	数据准备、轨迹覆盖、行为建模与模拟用户的统计评价
Zhao Dingcheng	语义检索、LLM/VLM 内容分析、证据核查与跨议题评价

Fu Yitong 与 Wang Junbo 按和 Zhao Dingcheng 共同制定的规范独立标注，再一起复核分歧。每位成员撰写实质性章节，并复核另一位的工作。每周会议检查证据和进度。

参考文献

[1] Milli, S., Carroll, M., Wang, Y., Pandey, S., Zhao, S., & Dragan, A. D. (2025). *Engagement, User Satisfaction, and the Amplification of Divisive Content on Social Media*. PNAS Nexus, 4(3), pgaf062.

[2] Vera, J. A., & Ghosh, S. (2025). *"They've Over-Emphasized That One Search": Controlling Unwanted Content on TikTok's For You Page*. arXiv:2504.13895.

[3] Pecher, B., et al. (2026). *Algorithmic Audit of Personalisation Drift in Polarising Topics on TikTok*. UMAP 2026.

[4] Draws, T., et al. (2023). *Viewpoint Diversity in Search Results*. ECIR 2023, pp. 279–297.

[5] Wang, W., Feng, F., Nie, L., & Chua, T.-S. (2022). *User-Controllable Recommendation Against Filter Bubbles*. SIGIR 2022, pp. 1251–1261.

[6] Kaplan, L., Patel, D., Gerzon, N., Mislove, A., & Sapiezynski, P. (2026). *When "For You" Isn't For You: Measuring User Agency in TikTok's Algorithmic Feed*. arXiv:2605.10690.

[7] Barua, A., Wang, L., & Zhang, A. X. (2026). *Compass: Continuously Aligning Social Media Feeds via In-Situ Reflections*. UIST 2026; arXiv:2608.04274.

[8] xAI. (2026). *x-algorithm* [Source code, commit b79b947].

[9] Shang, Y., Gao, C., Li, N., & Li, Y. (2025). *A Large-scale Dataset with Behavior, Attributes, and Content of Mobile Short-video Platform*. WWW Companion 2025, pp. 793–796.

[10] Gao, C., et al. (2022). *KuaiRand: An Unbiased Sequential Recommendation Dataset with Randomly Exposed Videos*. CIKM 2022, pp. 3953–3957. Caption/category supplement.

[11] Sukiennik, N., Wang, H., Zeng, Z., Gao, C., & Li, Y. (2025). *SimTok: Simulating Filter Bubble on Short-video Recommender System with Large Language Model Agents*. arXiv:2504.08742.

[12] Yoon, S., He, Z., Echterhoff, J. M., & McAuley, J. (2024). *Evaluating Large Language Models as Generative User Simulators for Conversational Recommendation*. NAACL 2024, pp. 1490–1504.